形式化研究 · Lean 4 + Mathlib

人机贡献的能识别边界

把「这份工作里有多少是人做的」从一句立场之争，
变成 117 条能被机器逐条检查的定理。



117
条已证定理

0
个 sorry 与公理

9
个形式化模块

CONTENTS

这份报告讲什么

01 **看不见的鸟** 「观测不到」从来不等于「不存在」

02 **检测能力的上限** 再怎么努力，也压不过那道物理天花板

03 **真相不是一个点** 观测协议决定了你能看见什么

04 **符号不由数据决定** 一个估计量连自己的正负都做不了主

05 **把争议变成定理** 117 条 Lean 4 证明，零 sorry 零公理

01

看不见的鸟

在谈 AI 之前，生态学家已经把这件事说过一遍了。

生态学 · 一个老故事

看不见的那只鸟

看不见 ≠ 不存在

- 鸟根本不在这一片林子里
- 鸟在，但天太黑、灌木太密
- 鸟在，但风太大、距离太远

重复调查能把看见的概率越推越高，但永远到不了 1。
那道天花板由观测协议决定，不由你有多认真决定。



在同一个观测协议下，所有「看起来一模一样」的状态被混在了一起。重复观测能提高检出率，但协议本身分辨不了的东西，永远检不出来。

问题 · 同一个错误

AI 正在重复这个错误

生态学家

- 看不见 → 记为「未检出」
- 参考分布：真实的物种分布
- 换一个观测协议 → 结论改变
- 重复调查 → 检出率上升

今天的 AI 辅助研究

- 检测不到 → 当成「不存在」
- 参考分布：文献里的既有结论
- 换一个模型或检测器 → 结论翻转
- 多跑几轮验证 → 真的会更准吗

今天的 AI 辅助科研，把「模型输出」当成了「观测本身」。但模型输出是一条有分辨率的通道。

02

检测能力的上限

这不是新发现，是几十年前的定理。但很少有人把它用到位。



内容层 · 结果一

最强检测器能做到什么，已经被算死了

TV / 2

任何检测器相对「瞎猜」能达到的最大优势

(1 − TV) / 2

最优检测器的最小错误率

TV = 两个分布有多不一样，取值 0 到 1 。 TV = 0 ，意味着你完全分不出两者的区别。

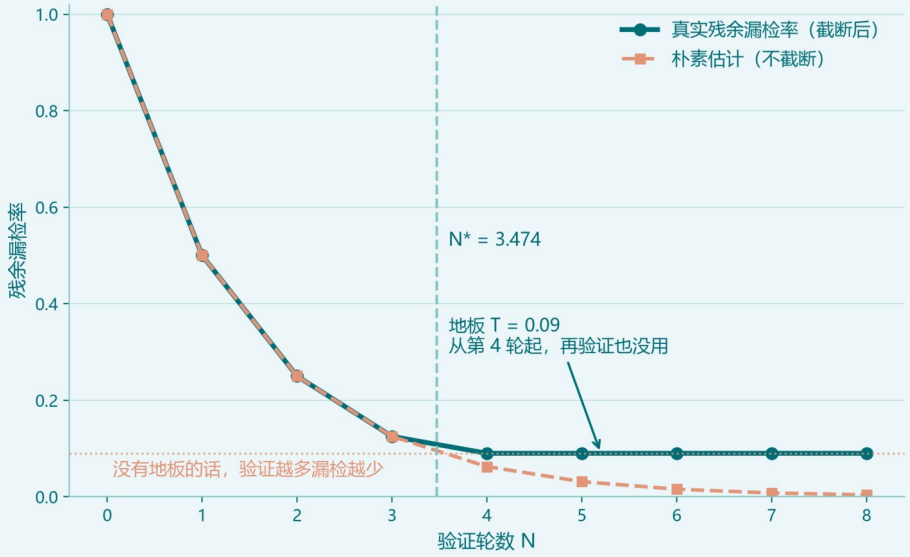
举个例子：参考分布 p=(0.42, 0.28, 0.18, 0.12) ，模型输出 q=(0.10, 0.20, 0.40, 0.30)

两者的 TV = 0.40 → 最好也只能比瞎猜强 0.20 ，错误率 0.30 。

来源：论文图 1 · 这是 Neyman–Pearson / Le Cam 两点引理，不是我们的新发现

内容层 · 结果二

验证不是越多越好



参数： TV = 0.09 、 q = 0.5 、 λ = 1 （与论文图 2 同源）

漏检率会往下掉，但掉到某个数就停住了

- 每多验证一轮，漏掉的概率就乘一次 —— 这是指数下降
- 但它有一个地板，无论验证多久都降不下去
- 地板高度 = λ × TV ： 检测器越弱，天花板越高

地板 T = 0.09 ： 再加多少验证者，也只能到这。

内容层 · 结果二（续）

预算卡在哪里：三个数

N_c

3·793

由验证者的可靠度决定

N_0

3·474

与人的能力无关的硬上界

N*

3·474

取较小者 —— 这里卡在 N_0

就算你的验证者再靠谱，预算也卡在 3.474 。

剩下那部分漏检，你加多少人都补不回来。

- **在 83.97% 的参数组合里，真正卡住我们的是检测器本身，而不是人。**

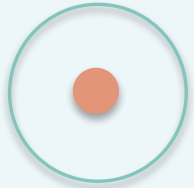
参数组： TV = 0.09 、 q = 0.5 、 λ = 1 ，与论文图 2 同源（ N_c 另取一组验证者可靠度）

03

真相不是一个点

换一个观测协议，「真相」就换了一个位置。

「真相」不是一个点，是一个等价类



老做法：把真实答案当成一个确定的点，然后去估计它离这个点有多远。

我们的做法：先问一句 —— 在这个观测协议下，哪些状态看起来完全一样？

它们组成一个等价类 [s*] 。于是误差从一个数字，变成一个随协议变化的层级函数。

协议严格



协议中等



协议宽松



同一个「真相」，在不同协议下被混在一起的状态并不相同。

系统层 · 结果三

贡献要拆成两笔账

人类的贡献：改变层级

- 提出一个更好问的问题
- 形式上：改变 Φ(α) 本身
- 收益没有上限

AI 的贡献：在层内压缩

- 把误差压向 Φ(α)
- 边际收益越来越小，有硬上界



AI 在层内能走的路有尽头（左边的小球撞了墙）；人往上换一层，路是没有尽头的。

「AI 越帮越忙」只在层固定时成立 —— 而层固定，正是人类不做贡献的状态。

系统层 · 反驳

影响力 ≠ 价值

+M

−M

两条输出，影响力的绝对值完全一样。

但一条的价值可以是 +M，另一条是 − M， M 还可以任意大。

结论：用「影响力」代理「价值」在数学上失效。
这不是工程问题，是定义问题。



KL 散度、互信息都只能测幅度：它们分不清「帮上忙」和「帮倒忙」。

价值必须带符号，幅度代替不了方向。

系统层 · 判决

「不可通约」这句话，其实要分两半说

当检测地板卡住了

完全不可通约

两个可靠度完全不同的人，给出完全相同的预算。
连高低都分不出来。

当地板没卡住

可通约，但非线性

谁强谁弱看得出来（保序）。
但不是成比例换算，做不成价格表。

准确的说法是「不可线性换算」，不是「完全不可通约」。
后者太强，会被定理直接判死 —— 这是形式化帮我们改掉的原话。

04

符号不由数据决定

我们找到的问题不在精度，而在方向。

标定层 · 问题

最通行的那个估计量，公式里没有人类

$$\hat{\varphi} = 1 - \bar{\tau} / \bar{s}$$

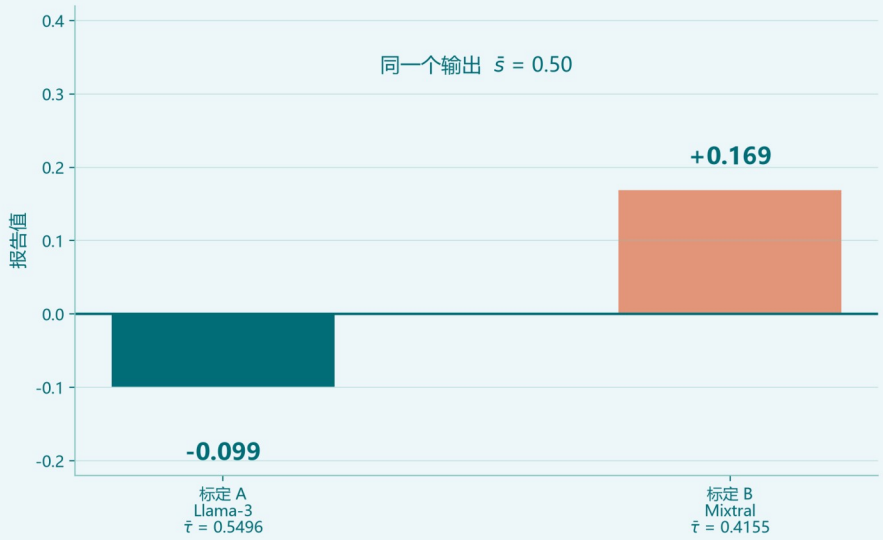
$\bar{\tau}$ = 拟合出来的那条「合理线」

$\bar{s}$ = 这段输出的平均意外程度

人类的输入 x 根本不在这个式子里。

所以它算出来的是「这段输出有多出人意料」，而不是「这里面有多少是人做的」。

同一个输出，两次标定，正负相反



固定一个输出： $\bar{s}$ **= 0.50**

标定 A • Llama-3： $\bar{\tau}$ **= 0.5496**
报告 − 0.099 → 判为「几乎没人」

标定 B • Mixtral： $\bar{\tau}$ **= 0.4155**
报告 +0.169 → 判为「有人参与」

同一段文字、同一份数据，结论完全相反。

差别只在于：你把那条「合理线」画在了哪里 —— 而这条线是在 2500 条与本任务无关的公开对话上拟合出来的。

$\bar{\tau}$ 取自 Xie et al. (ACL 2026) 附录 A.5

标定层 · 后果

它甚至不是一个比例

有上界

φ̂ 永远小于 1。

输出越出人意料，它越接近 1。

没有下界

输出越「意料之中」，它越小。

可以是任意负数，没有底线。

所以把它读成「0 到 1 之间的一个比例」，在估计版本里并不成立。

作者自己观察到这些负值，并在他们的框架内部给出了正确解释：

“could plausibly have been generated with minimal or negligible human contribution” — Xie et al., §5.5

05

把争议变成定理

117 条定理，零 sorry，零公理。

形式化

117 条定理，分布在 9 个模块里

全变差
Basic

污染
Contamination

覆盖
Coverage

假设检验
HypothesisTest

分层与观测等价
Refinement

影响力与价值
Value

验证预算
VerifyBudget

不可通约
Incommensurable

标定不可识别
Calibration

Lean 4 v4.15.0 + Mathlib • 117 条定理 + 20 个精确算例 • 零 sorry • 零公理 • 全量构建通过

形式化的价值

第一个被它抓出来的，是我们自己

一个不等式写反了

定理直接证不出来。 Lean 把我们自己的建模错误判了死刑。

残余项漏了一个地板

「验证越多越好」被推翻 —— 漏检率有一个降不下去的下限。

两条单调性方向写反

我们以为预算随检测能力单调递减，结论其实要更精细。

「完全不可通约」太满

被逼着改成准确说法：「不可线性换算」。

一个能扛过定理证明器的建模错误，大概也扛不过一个合作者。

结语

我们证明了什么

- 看不见 ≠ 不存在。 AI 把模型输出当成了观测本身。
- 检测能力有物理天花板，努力压不过去。
- 验证预算有一个与人的能力无关的硬上界。
- 影响力测不了价值 —— 价值必须带符号。
- 符号本身也不可识别：正负由一条分布外拟合的门槛决定。
- 117 条定理，零 sorry 零公理，全量构建可复跑。

我们不打击任何已有度量 —— 它们对各自声明的用途是有效的。
我们做的，是把他们散文式的警告，变成机器可以逐条检查的定理。